

大模型技术分享

MIWEAR X AI

吴文龙

软件工部部

2025年11月20日

大纲（偏科普）



签到码



- 大模型是如何从0到1构建的
- Vibe Coding 氛围编程新范式
- 可穿戴 x 大模型的一些思考




- 大模型是如何从0到1构建的
- Vibe Coding 氛围编程新范式
- 可穿戴 x 大模型的一些思考

• 什么是大模型 Large Language Model (LLM)?



<https://huggingface.co/Qwen/Qwen3-32B>



64GB

模型权重

~500 lines of C code

推理代码


Macbook



模型权重是如何来的？



可以认为是压缩了整个互联网的知识





整个互联网知识



6千块GPU训练了12天
花费了至少2千万人民币

Common Crawl



大约 15 万亿 (15 trillion) token




parameters.zip

~64GB 权重文件

• 怎么训练？Next Word Prediction 预训练



床 →
前 →
明 →
月 →



→ 光 (97%)
预测下一个词

举例：上下文 (context) 4个词 (token)

• Next Word Prediction 预训练让神经网络学到了世界知识




☆ 收藏 | 16984 | 2104

杨振宁 (Chen Ning Yang ^[177], 1922年10月1日—2025年10月18日) ^[2], 出生于安徽合肥 ^[175], 字伯瓊, 理论物理学家 ^[70], 中国科学院院士 ^[1]、美国国家科学院外籍院士、英国皇家学会外籍院士、香港科学院荣誉院士 ^[137]、俄罗斯科学院外籍院士 ^[149], 诺贝尔物理学奖获得者, 生前为香港中文大学博文讲座教授兼理论物理研究所所长 ^[148], 清华大学高等研究院名誉院长、教授, 纽约州立大学石溪分校荣休教授 ^[81]。

1942年毕业于西南联合大学物理系。1944年获得清华大学硕士学位 ^[183]。1948年获得芝加哥大学物理系哲学博士学位。1949年至1966年任职于普林斯顿高等研究院 ^[2]。1964年3月入籍美国 ^[57]。1965年当选美国国家科学院院士。1966年至1999年任纽约州立大学石溪分校爱因斯坦讲座教授、理论物理研究所所长 ^[142]。1986年起任香港中文大学博文讲座教授。1999年起任清华大学教授 ^[159]。2015年4月放弃美国国籍 ^[57]。2017年2月转为中国科学院院士 ^[19]。2025年10月18日在北京逝世, 享年103岁 ^[141]。

杨振宁主要从事统计力学和对称原理、粒子物理研究 ^[1]。1954年与米尔斯提出“杨-米尔斯规范场论”, 奠定后来粒子物理标准模型的基础, 被认为是现代物理学的基石之一。1956年与李政道合作提出弱作用中宇称不守恒的革命性思想, 并获1957年诺贝尔物理学奖。1972年与巴克斯特提出“杨-巴克斯特方程”, 开辟统计物理和量子群等物理和数学研究新方向 ^[159]。曾获美国国家科学奖章、富兰克林奖章、爱因斯坦奖章、玻戈留波夫奖、昂萨格奖、费萨尔国王国际科学奖、中国国际科技合作奖、求是终身成就奖等 ^[142]。

2023	2023	2024
Llama-1	Llama-2	Llama-3
1.4T tokens	2T tokens	15T tokens



• 预训练后，还得接着训练助理模型 -instruct/-chat




用户：
小米是哪一年创立的？

大模型：
小米的创始人是谁？除了广为人知的雷军，其他几位联合创始人分别是谁？他们被内部和粉丝称为什么？



用户：
小米是哪一年创立的？

大模型：
好的，小米公司成立于 2010年4月6日。



整个互联网知识
10T文本数据

<USER>

Can you write a short introduction about the relevance of the term "monopsony" in economics? Please use examples related to potential monopsonies in the labour market and cite relevant research.

<ASSISTANT>

"Monopsony" refers to a market structure where there is only one buyer for a particular good or service. In economics, this term is particularly relevant in the labor market, where a monopsony employer has significant power over the wages and working conditions of their employees. The presence of a monopsony can result in lower wages and reduced employment opportunities for workers, as the employer has little incentive to increase wages or provide better working conditions...



- 由人撰写
- 大约10万条对话


继续训练，获得助理模型
(SFT)

• 强化学习 Reinforcement Learning (RL) 训练



prompt: 树上骑个🐵，地下一个🐵，请问有几个🐵?

助理
模型
回答



一共两个🐵




一共生成12个候选答案，只有4次是正确的。

结合其他的标准（结构简单、是中文）选择，选择正确的答案，进行训练

需可验证 reward 来判断正确：math、code...

重复许多许多次！目的是让模型不断实践、学会自己思考 thinking

• 强化学习其实并不是什么新技术 - AlphaGo 2017年



Mastering the game of Go with deep neural networks and tree search

DeepSeek 第一个揭开了OpenAI O1模型的秘密




Figure 2 | AIME accuracy of DeepSeek-R1-Zero during training. For each question, we sample 16 responses and calculate the overall average accuracy to ensure a stable evaluation.




Figure 3 | The average response length of DeepSeek-R1-Zero on the training set during the RL process. DeepSeek-R1-Zero naturally learns to solve reasoning tasks with more thinking time.

自我验证、反思、长思维链

Question: If $a > 1$, then the sum of the real solutions of $\sqrt{a - \sqrt{a + x}} = x$ is equal to

Response: <think>

To solve the equation $\sqrt{a - \sqrt{a + x}} = x$, let's start by squaring both ...

$$(\sqrt{a - \sqrt{a + x}})^2 = x^2 \Rightarrow a - \sqrt{a + x} = x^2.$$

Rearrange to isolate the inner square root term:

$$(a - x^2)^2 = a + x \Rightarrow a^2 - 2ax^2 + (x^2)^2 = a + x \Rightarrow x^4 - 2ax^2 - x + (a^2 - a) = 0$$

...

Wait, wait. Wait. That's an aha moment I can flag here.

Let's reevaluate this step-by-step to identify if the correct sum can be ...

We started with the equation:

$$\sqrt{a - \sqrt{a + x}} = x$$

First, let's square both sides:


$$a - \sqrt{a + x} = x^2 \Rightarrow \sqrt{a + x} = a - x^2$$

Next, I could square both sides again, treating the equation: ...

...

Table 3 | An interesting "aha moment" of an intermediate version of DeepSeek-R1-Zero. The model learns to rethink using an anthropomorphic tone. This is also an aha moment for us, allowing us to witness the power and beauty of reinforcement learning.

• "把大象装进冰箱": 如何训练你的 ChatGPT/Deepseek



~每年更新

阶段1: 预训练 Pretraining

1. 下载10TB左右的文本数据
2. 买/租6000多台的GPU
3. 将文本压缩进模型, 花费2千万, 等12天
4. 获得 base模型



<USER>

Can you write a short introduction about the relevance of the term "monopsony" in economics? Please use examples related to potential monopsonies in the labour market and cite relevant research.

<ASSISTANT>

"Monopsony" refers to a market structure where there is only one buyer for a particular good or service. In economics, this term is particularly relevant in the labor market, where a monopsony employer has significant power over the wages and working conditions of their employees. The presence of a monopsony can result in lower wages and reduced employment opportunities for workers, as the employer has little incentive to increase wages or provide better working conditions...

~每周更新

阶段2: 后训练 Post-training

1. 制定构建对话集的标准
2. 雇人写10万条高质量的问答或偏好集
3. 在该数据集上微调base模型, 等1天
4. (可选: 强化学习训练)
5. 获得 assistant/thinking模型
6. 进行一系列评估
7. 部署上线
8. 监控, 收集错误回答, 回到step 1

大模型幻觉 Hallucinations



谭鹰：中国中高端酒店业领军人物

介绍一下谭鹰这位企业家

好的，很乐意为您介绍谭鹰先生。

谭鹰是一位在中国酒店业，特别是中高端酒店领域非常有影响力的企业家和行业革新者。他最为人熟知的身份是东呈国际集团的创始人、董事长。

以下是关于他的详细介绍：

核心身份

- 东呈国际集团创始人兼董事长：他于2006年创立了“城市便捷酒店”品牌，并以此为基础，将东呈发展成为中国领先的酒店集团之一。

创业历程与商业成就

- 从地产到酒店的革命性洞察：
谭鹰先生并非酒店管理科班出身，他早期在房地产行业积累了丰富经验。正是这段经历让他敏锐地察觉到，当时中国经济型酒店虽然蓬勃发展，但普遍存在“重投资、轻体验”的问题，缺乏对用户核心需求的关注。他看到了在“精品快捷”酒店领域的巨大市场空白。
- 创立“城市便捷”与“东呈国际”：
 - 2006年：他在广西南宁创办了第一家“城市便捷酒店”，开创性地提出了“睡好一点”的核心品牌理念。

Message DeepSeek

DeepThink Search

AI-generated, for reference only



小米手表SSX功能与特点介绍

介绍一下小米SSX这款手表

好的，很乐意为您介绍小米手表 SSX。

首先需要明确一点：小米手表 SSX 是中国大陆市场独有的型号，它在全球其他市场对应的型号是小米手表 S2（具体是 42mm 版本）。所以如果您看到关于小米手表 S2 42mm 的介绍，其功能特性基本与 SSX 一致。

SSX 是一款定位时尚、轻智能、长续航的中端智能手表，主打高颜值和全面的健康管理功能，性价比比较高。

以下是关于小米手表 SSX 的详细介绍：

核心亮点

- 双尺寸设计与时尚外观：提供 42mm 和 46mm 两种尺寸（SSX 特指 42mm 版，但系列中包含 46mm），采用金属中框和多种材质的表带，外观精致，更像传统腕表，适合不同手腕粗细和穿搭风格。
- 超长续航：典型使用模式下，续航可达 10-12 天，即使在重度使用下也能轻松支撑一周，告别一天一充的烦恼。
- 专业的健康监测：搭载了小米澎湃智联，支持心率、肌肉量、蛋白质等身体成分测量（需配合底座电极），同时具备心率、血氧饱和度、压力、睡眠等全面监测。
- 丰富的运动模式：内置超过 150+ 种运动模式，并能自动识别多种常见运动，满足从专业到日常的广泛需求。

Message DeepSeek

DeepThink Search

AI-generated, for reference only



小米科技园E栋小说介绍

介绍小米科技园E栋这本小说

好的，这本名为《小米科技园E栋》的小说，是目前网络上非常受欢迎的一部都市职场现实题材作品。它并非官方出品，而是由网友或网络作家创作的“同人小说”，但因为其极其真实的背景和强烈的共鸣感而走红。

下面为您详细介绍一下这部小说：

核心概览

- 书名：《小米科技园E栋》
- 作者：匿名（网络连载，作者身份未公开）
- 类型：都市、职场、现实、群像、互联网行业
- 核心设定：故事以真实存在的北京小米科技园E栋办公楼为主要舞台，聚焦在其中工作的普通员工，描绘了他们在高压环境下的工作、生活、情感与挣扎。

主要内容与情节

小说没有单一的、戏剧化的主线情节（如商战、霸总），而是采用多线程并行的“群像戏”手法，通过多个典型角色的视角，拼凑出一幅鲜活而残酷的互联网大厂浮世绘。

主要情节围绕以下几个方面展开：


Message DeepSeek

DeepThink Search

AI-generated, for reference only



是什么导致了幻觉？模型为什么会幻觉？



事实上，我们并不知道这些参数代表了什么含义！！😂😂

- 数千亿/万亿参数随机分布在神经网络
- 我们只知道如何优化他，让他每次迭代更准确
- 我们可以评估他能够work，但是不知道这些参数具体是怎么合作work的

预训练让大模型获得了知识，但是他对知识的掌控却有点奇怪：



Recent viral example: "reversal curse"

Q: "Who is Tom Cruise's mother?"

A: Mary Lee Pfeiffer ✓

Q: "Who is Mary Lee Pfeiffer's son?"

A: I don't know ✗



该如何缓解LLM幻觉呢？方式一：可以说不知道



根据下面的段落生成 3 个具体的、基于事实的问题。除了问题之外，还要生成正确答案。

Xiaomi MiMo 是小米公司于 2025 年 4 月 30 日开源的首个推理大模型。由该公司大模型 Core 团队研发。通过预训练与后训练联动机制提升推理能力。该模型参数规模为 78B。在数学推理 (AIME 24-25) 和代码竞赛 (LiveCodeBench v5) 测评中，性能超过 OpenAI 的闭源推理模型 o1-mini 及阿里 Qwen 的开源推理模型 Qwen-3-72B-Preview [1-2]。该模型采用三阶段预训练流程，累计训练 25T tokens 数据，其中合成约 200B tokens 推理专用数据。后训练阶段引入 Test Difficulty Driven Reward 算法和 Easy Data Re-Sampling 策略，并通过 Seamless Rollout 系统实现强化学习训练加速 2.29 倍，验证加速 1.96 倍 [1-2]。前 DeepSeek 研究员罗福前参与 MiMo 模型的核心研发工作 [3]。

下面是基于给定段落生成的 3 个具体的、基于事实的问题，并附上对应的 正确答案：

问题 1
问：Xiaomi MiMo 模型在 2025 年 4 月 30 日开源时，其参数规模是多少？
答：该模型的参数规模为 78B。

问题 2
问：在数学推理 (AIME 24-25) 和代码竞赛 (LiveCodeBench v5) 测评中，Xiaomi MiMo 的性能超过了哪两个模型？
答：超过了 OpenAI 的闭源推理模型 o1-mini 和阿里 Qwen 的开源推理模型 Qwen-3-72B-Preview。

问题 3
问：在训练阶段，为提升 MiMo 模型的效率，采用了哪些优化策略？
答：采用了 Test Difficulty Driven Reward 算法、Easy Data Re-Sampling 策略。

如需更多数据、数据集、应用内的预训练数据集，也可以告诉我！

小米 MiMo 模型开源参数规模

Xiaomi MiMo 模型在 2025 年 4 月 30 日开源时，其参数规模是多少？


您好！这是一个关于小米 (Xiaomi) 最新大模型的重要问题。

根据小米在 2025 年 4 月 30 日官方开源时发布的信息，Xiaomi MiMo 模型是一个混合专家模型，其总参数量为 241B (24.1B)。激活参数量为 29B (2.9B)。

这里为您提供更详细的说明：

- 模型名称与特点：**模型的全名是 Xiaomi MiMo。它是一个 MoE (混合专家) 模型。这意味着它拥有一个庞大的总参数量 (241B)，但在具体的输入时，只会激活和运用其中的一小部分参数 (29B)。这种设计可以在保持高性能的同时，获得接近超大模型的性能。
- 开源许可证：**该模型采用 Apache 2.0 许可证，对商业使用非常友好。
- 性能表现：**根据小米官方公布的基准测试结果，MiMo-24.1B 在多项中英文通用能力评测 (如 MMLU, C-Eval) 中，其性能已经超过了参数量更大的主流模型，如 Llama 3-70B 和 Qwen 2-72B，展现了极高的效率。

相同地，用 SFT 可以解决很多问题 (打补丁)



构建数据集

用户：Xiaomi MiMo 模型在 2025 年 4 月 30 日开源时，其参数规模是多少？

AI: Sorry, blabla, 我不知道。。。

SFT




Claude 3.7
GPT 5.1
Deepseek v3.2

• 该如何缓解LLM幻觉呢？方式二：查资料





Retrieval-augmented generation (RAG)





大模型评估方式一：标准数据集评测



评测类型	代表榜单	主要测什么	主要使用者 / 模型
① 综合通用能力	MMLU (Massive Multitask Language Understanding)	57 个学科的综合知识与推理	✓ GPT-4 / Claude / Gemini / Qwen / Yi / Baichuan 等几乎都使用
	BBH (BIG-Bench Hard)	高难度推理与常识问题	GPT-4 / Claude / Gemini
	AGIEval	模拟人类考试题 (GRE, SAT, 司法等)	Qwen / Yi / GPT-4
② 数学与逻辑推理	ARC / HellaSwag	常识与科学推理	OpenAI, Anthropic
	GSM8K	小学—初中数学文字题	GPT-4 / Qwen / Yi / Claude
	MATH	高中—奥数级数学推理	GPT-4 / Gemini / Qwen2-Math
	Minerva Benchmark	科学、公式、单位理解	Google DeepMind
③ 编程与代码能力	HumanEval	Python 函数生成正确率	GPT-4 / Qwen / Yi / InternLM / CodeLLaMA
	MBPP	基础编程任务	OpenAI & Google
	MultiPL-Eval	多语言编程能力	DeepSeek-Coder / CodeLLaMA
④ 中文综合能力	C-Eval	52 个中文学科考试题	✓ 所有中文模型 (Qwen, Yi, Baichuan, InternLM)
	CMMLU	中文版 MMLU (67 学科)	Qwen / Yi / OpenCompass
	GAOKAO-Bench	高考类题集 (语数英)	Qwen / Baichuan
⑤ 事实性与真实性	TruthfulQA	是否生成错误或误导性回答	GPT / Claude / Gemini / Qwen
	FactScore / HaluEval	幻觉率、事实一致性	各大实验室评估
⑥ 安全与鲁棒性	SafetyBench	安全性、有害内容防御	Anthropic / OpenAI
	AdvBench / BiasBench	对抗攻击与偏见检测	Research Labs
⑦ 多语言能力	XQUAD, Flores-200	多语言问答、翻译	Gemini / GPT-4-Turbo / Qwen2
⑧ 多模态能力 (图文理解)	MMBench, MM-Vet, MME, SEED-Bench, MathVista	图文理解、OCR、视觉推理	✓ GPT-4V / Gemini 1.5 Pro / Qwen-VL / Yi-VL



大模型评估方式二：人类偏好评测 - LMArena




• "哪个大模型最好用？", 2025年11月中旬版 - LMArena



文本排行榜

Text 1 day ago			
Rank (UB) ↑↓	Model ↑↓	Score ↓	Votes ↑↓
1	gemini-2.5-pro	1452	62,764
1	claude-sonnet-4-5-20250929-t...	1449	13,853
1	claude-opus-4-1-20250805-thi...	1448	29,426
2	gpt-4.5-preview-2025-02-27	1442	14,644
2	claude-opus-4-1-20250805	1439	41,950
4	chatgpt-4o-latest-20250326	1438	48,510
4	gpt-5-high	1436	30,974
2	claude-sonnet-4-5-20250929	1436	5,476
4	o3-2025-04-16	1434	59,391
4	qwen3-max-preview	1432	25,932
View all			



业界最全面、最及时、最权威的评测榜单

Last Updated	Total Votes	Total Models
Nov 10, 2025	4,492,652	261

不同角色的人需要看的榜单不一样



写代码？看这个

Rank (US)	Model	Score	95% CI (x)	Votes	Organization	License
1	AI claude-sonnet-4.5-20250929-thinking-32k	1525	+11	3,034	Anthropic	Proprietary
1	AI claude-opus-4-1-20250805-thinking-16k	1514	+9	5,669	Anthropic	Proprietary
2	AI claude-opus-4-1-20250805	1501	+8	8,189	Anthropic	Proprietary
3	AI claude-opus-4-20250814-thinking-16k	1495	+8	6,744	Anthropic	Proprietary
4	Qwen3-max-preview	1482	+9	4,938	Alibaba	Proprietary
4	AI claude-haiku-4-9-20251001	1476	+12	2,523	Anthropic	Proprietary
4	Qwen3-max-2025-09-23	1474	+13	2,045	Alibaba	Proprietary
5	longcat-flash-chat	1474	+13	2,252	Meltan	MIT
3	kimi-k2-thinking	1473	+14	618	Moonshot	Modified MIT
5	Z glin 4.6	1472	+12	2,392	Z.ai	MIT

写小说？看这个

Rank (US)	Model	Score	95% CI (x)	Votes	Organization	License
1	AI claude-sonnet-4.5-20250929	1480	+22	735	Anthropic	Proprietary
1	Gemini-2.5-pro	1452	+8	8,128	Google	Proprietary
1	AI claude-sonnet-4.5-20250929-thinking-32k	1440	+14	1,802	Anthropic	Proprietary
1	AI claude-opus-4-1-20250805-thinking-16k	1439	+10	3,754	Anthropic	Proprietary
1	GPT-4.5-preview-2025-02-27	1433	+12	2,645	OpenAI	Proprietary
2	AI claude-opus-4-1-20250805	1430	+9	5,363	Anthropic	Proprietary
3	AI claude-opus-4-20250814-thinking-16k	1420	+9	4,685	Anthropic	Proprietary
1	Qwen3-72B-Preview-1022	1419	+29	433	Baidu	Proprietary
4	chatgpt-4o-latest-20250326	1419	+8	6,622	OpenAI	Proprietary
7	AI claude-opus-4-20250814	1410	+8	5,737	Anthropic	Proprietary

做数学题？看这个

Rank (US)	Model	Score	95% CI (x)	Votes	Organization	License
1	AI claude-sonnet-4.5-20250929-thinking-32k	1462	+21	751	Anthropic	Proprietary
1	Gemini-2.5-pro	1457	+10	3,878	Google	Proprietary
1	Qwen3-max-preview	1455	+10	3,800	OpenAI	Proprietary
1	AI claude-opus-4-1-20250805-thinking-16k	1445	+14	1,738	Anthropic	Proprietary
1	Qwen3-max-preview	1445	+16	1,405	Alibaba	Proprietary
1	Grok-4-9-089	1442	+14	1,907	xAI	Proprietary
1	AI claude-opus-4-1-20250805	1441	+12	2,444	Anthropic	Proprietary
1	GPT-5-high	1440	+14	1,844	OpenAI	Proprietary
1	Qwen3-max-2025-09-23	1436	+23	595	Alibaba	Proprietary
1	Gemini-2.5-flash-preview-00-2025	1434	+21	769	Google	Proprietary

说中文？看这个

Rank (US)	Model	Score	95% CI (x)	Votes	Organization	License
1	Gemini-2.5-pro	1495	+12	3,234	Google	Proprietary
1	Qwen3-max-preview	1491	+17	1,326	Alibaba	Proprietary
1	Z glin 4.6	1482	+33	328	Z.ai	MIT
1	Deepseek-v3.1-thinking	1473	+21	872	DeepSeek	MIT
1	Xin 4-test	1473	+31	379	xAI	Proprietary
2	Deepseek-v3.1	1462	+18	1,115	DeepSeek	MIT
2	chatgpt-4o-latest-20250326	1461	+13	2,385	OpenAI	Proprietary
1	Gemini-2.5-flash-preview-00-2025	1461	+28	452	Google	Proprietary
3	Qwen3-72B-Preview-1022	1459	+12	2,874	OpenAI	Proprietary
1	Qwen3-72B-Preview-1022-Instruct	1457	+31	333	Alibaba	Apache 2.0



- 大模型是如何从0到1构建的
- **Vibe Coding 氛围编程新范式**
- 可穿戴 x 大模型的一些思考

• AI 正在改变软件开发



2023 自动补全

帮助开发者
更快地写代码

2024 代码助手

生成更大的代码段
并回答问题

2025 智能体

在人员参与的情况下
端到端完成开发任务

人人都是开发者

• 什么是 Vibe Coding 氛围编程?



Andrej Karpathy
@karpathy



There's a new kind of coding I call "vibe coding", where you fully give in to the vibes, embrace exponentials, and forget that the code even exists. It's possible because the LLMs (e.g. Cursor Composer w Sonnet) are getting too good. Also I just talk to Composer with SuperWhisper so I barely even touch the keyboard. I ask for the dumbest things like "decrease the padding on the sidebar by half" because I'm too lazy to find it. I "Accept All" always, I don't read the diffs anymore. When I get error messages I just copy paste them in with no comment, usually that fixes it. The code grows beyond my usual comprehension, I'd have to really read through it for a while. Sometimes the LLMs can't fix a bug so I just work around it or ask for random changes until it goes away. It's not too bad for throwaway weekend projects, but still quite amusing. I'm building a project or webapp, but it's not really coding - I just see stuff, say stuff, run stuff, and copy paste stuff, and it mostly works.

7:17 AM · Feb 3, 2025 · 5.1M Views

有一种全新的编程方式，我称之为“氛围编程”——你完全沉浸在氛围里，拥抱指数级增长，甚至忘了代码的存在。之所以能做到，是因为大语言模型（比如 **Cursor Composer + Sonnet**）已经强得离谱。我还用 SuperWhisper 直接对着 Composer 说话，几乎不用碰键盘。我会提最懒的要求，比如“侧边栏内边距给我减半”，因为我连找都懒得去找。我永远还是“全部接受”，diff 也不看了。报错就整段复制粘贴进去，通常就能修好。代码膨胀到我自己都看不懂，得花好一会儿才能读明白。有时候大模型也修不了 bug，我就绕过去，或者瞎提点随机改动，直到它消失为止。对周末扔就扔的小项目来说，这办法还行，挺好玩。

定义：

通过自然语言与智能体助手完成结对编程：
凭感觉、凭经验、凭直觉的编码方式

优势：

- 灵活
- 创意
- 适合早期探索



Ricky
@rickyrobinett


Follow




What can an 8-year-old build in 45 minutes with the assistance of AI?

My daughter has been learning to code with [@cursor.ai](#) and it's mind-blowing 🤯

Here are highlights from her second coding session. In 45 minutes she built a chatbot powered by [@CloudflareDev](#) Workers AI 🚀



• Vibe Coding 的黄金时代：10倍的个人效率提升不是梦



1. 探索期（不只是程序员）
 - 快速造东西、验证方向
2. 收敛期
 - 工程化模式
 - 重做框架和代码质量



Joey Wang
@joeysywang

Follow



I built a vibe coding keyboard with just 8 keys
And I'm bringing it to work tomorrow.

It has:

- everything you need to use [@claude.code](#)
- a mouse to use the app you just vibe coded
- touch grass button

I even use it to vibe code itself, demo in 📺 🎧




• 从“写代码”到“管理代码”，从开发者到架构师




开发者 = 代码生产者

角色转变

开发者 = 架构师 + 审核者




能跑吗
功能有BUG吗



到底要解决什么问题
解决问题的方法是最优的吗
性能如何，质量如何

• Vibe Coding 智能体编程有哪些挑战?




功能实现唾手可得，然后
项目规模越大效率越低

Vibe Coding 成功关键因素



- AI 工具的选择
- 用的什么模型
- 用哪些MCP（工具）
- 提示词的质量
- AI执行规范（规则）




📖 Mi Code CLI 使用说明书

工具	Cursor	Codex CLI	Claude Code	Mi Code CLI
定位	AI 原生 IDE，基于 VS Code 深度改写	云端AI编程智能体，同时提供终端(CLI)和IDE插件	命令行工具，基于 Claude，强调自主编程	命令行工具，基于 Gemini CLI 类似于 Claude Code 的体验
核心功能	项目级代码理解，Composer 多文件编辑，多模态支持（图片/代码）	终端自然语言交互；自动化执行任务(创建文件、运行脚本)；理解代码库、修复 bug、提交拉取请求(PR)	依赖 Claude API，需自行配置	中文友好，代码补全、解释、优化，支持主流语言
模型支持	内置 GPT-4/Claude/Gemini 等，支持自定义 API	GPT-5/GPT-5-Codex	仅限 Claude 模型	DeepSeek-V3.1-Terminus / Kimi-K2-Instruct-copilot / GLM-4.6 / Gemini-2.5-Flash / Gemini-2.5-Flash-Lite / Gemini-2.5-Pro / GPT-5 / GPT-5-Mini / GPT-5-Nano
隐私性	企业版提供隐私保护，普通版需联网	主要在云端沙盒环境运行；终端使用需联网	企业版提供隐私保护	GLM-4.6 / Gemini-2.5-Flash / Gemini-2.5-Flash-Lite / Gemini-2.5-Pro / GPT-5 / GPT-5-Mini / GPT-5-Nano 都是外部模型
适用场景	中大型项目开发，需深度代码理解与多文件协作	中大型项目自动化任务；快速原型开发；技术和非技术用户均可使用	命令行爱好者，适合中大型项目，自动化要求高	中文开发者，快速补全与基础优化
价格	Pro 版 \$20/月，免费版有限额	ChatGPT Plus 用户 (\$20/月) 可用；CLI 模式有免费API配额，超出后按量计费	每日免费 \$25 额度，用完需自费	免费
优势	无缝衔接 VS Code，项目级理解强，代码自动补齐能力	项目理解深，自动化程度高；与 GitHub 工作流集成；支持并行处理多项任务	项目感知高，自动化程度高，代码质量高，适合中大型项目	深度项目感知，快速读取并理解整个代码仓库结构，超强编码能力，可自主完成代码编辑、测试修复等全流程任务



• 实践中建议对 AI 能力的采用框架





- 大模型是如何从0到1构建的
- Vibe Coding 氛围编程新范式
- 可穿戴 x 大模型的一些思考

• 运动健康 AI 业界两大方向



一、运动健康 AI 布局的业界两大研究方向

1. 生理信号大模型：通过自监督学习路线，训练能够理解人体多模态生理信号的基础模型，提升心率、血压、睡眠等下游任务的测量**准确度**，模型规模为**千万级**（对比大语言模型规模在十亿级），适合在表端落地。
2. 健康Agent助手：**基于Gemini大模型**的自身能力，在不微调的前提下，通过工具调用、知识库检索和多步推理等方式，增强LLM对领域知识、**多维生理指标洞察分析**等的处理能力，实现专业与个性化的健康Agent助手。

二、生理信号大模型架构

生理信号大模型的训练分为两个颗粒度层面：

1. 原始信号层，提升基础生理指标准确度：以PPG、ACC、ECG等原始传感器波形为输入，捕捉细粒度的底层时序特征；
 2. 指标结果层，提升生理风险预测准确度：以心率、血压、血氧等汇总结果指标为输入，学习**轻量化**的健康风险分析
- 苹果在两个方向持续发力，今年推出**Apple Watch 高血压风险（通过了FDA）**基于此技术。谷歌选择在第二个方向指标结果层预训练，通过自监督学习路线，在4千万小时多模态穿戴数据训练，学习理解多种生理模态的规律与关联，在下游任务预测（如运动检测、活动识别等）提升16%~47%的准确度。

三、健康Agent助手技术架构

Agent方向目前只有谷歌在重点布局，苹果则没有公开信息参考。

1. 目标：基于Gemini大模型，采用多Agent架构，将3个Agent动态结合，协同解决用户需求
2. 实现方式
 - a. 从用户需求出发，调研梳理4类核心需求（健康科普、数据洞察、生活方式建议、症状解释）
 - b. 根据用户需求，针对性设计3款Agent各司其职：
 - 数据分析Agent：把个人可穿戴数据利用代码转为可复现的统计结果
 - 领域专家Agent：以权威来源为依据，结合个体上下文进行医学解释与推理
 - 健康教练Agent：将结果落到个性化、可执行的行动计划与行为改变
3. 结果：在用户与专家两个维度评估，显著优于单Agent与其他业界Agent（盲选80%胜率）

运动健康 AI 业界技术演进



终极目标：构建以运动健康为核心的多模态大模型驱动的主动智能AI助理，实现基于用户生理、行为、环境、语音等数据的跨模态理解与智能化主动服务


方向一：生理信号大模型

方向二：健康Agent助手

单模态-精准识别

多模态-场景感知


Agent-主动智能



从精准识别到多模态感知，再到主动智能，苹果、谷歌与学界正在持续发力，生理信号大模型持续演进，迈向运动健康大模型/智能体。

可穿戴x大模型-技术路线梳理

• 生理信号大模型：全面超越传统 AI 算法




生理信号大模型依托海量可穿戴数据，在统一架构下完成训练，并在多任务验证中**全面优于传统AI方法**，显著提升预测性能。

• 生理信号大模型 - 自监督学习的技术分支




对比学习路线




通过**比较同一人与不同人的信号**，引导模型**抓住个体差异和自身稳定特征**，从而显著提升模型的识别能力和泛化水平。

遮掩学习路线



通过在训练中**刻意遮挡部分信号**，引导模型**理解数据的规律与趋势**，并在此基础上具备补全缺失、预测变化和识别行为的能力。

• 生理信号大模型 - 对比学习路线，苹果已落地一项功能



健康Agent助手 - 多Agent架构（谷歌 Personal Health Agent）



1. 需求来源

a. 线上健康查询与社区讨论

- 从搜索引擎、Gemini、Fitbit 论坛中抽取并综合了1370条消费者健康问题，了解用户日常最关心的话题和疑惑，例如锻炼效果、睡眠、健康风险。

b. 用户体验调查

- 借助Fitbit Labs的Insight Explorer项目，对555名消费者进行使用体验调查，收集可穿戴设备与健康应用的痛点反馈。

c. 专家设计工作坊

- 召集14位来自UX、工程、科研的专家共同参与设计工作坊，帮助把用户的零散问题转化为可操作的设计目标，并保证技术与医学可行性。

2. 需求归纳

在收集原始问题后，研究团队进行了系统梳理，最终提炼出4个核心用户需求：

a. 需求1: 一般健康知识

- 解决常见健康科普问题，如“HIIT 有什么利弊？”，“链球菌感染会传染多久？”

b. 需求2: 个人数据理解

- 帮助用户理解可穿戴设备数据，例如“我的步数在过去一个月是如何影响静息心率的？”

c. 需求3: 健康与生活方式建议

- 给出可操作的生活方式指导，如“我应该几点睡觉来提高睡眠分数？”

d. 需求4: 个人症状解释

- 帮助初步理解可能的健康状况，例如“喉咙痒、吞咽困难可能是什么原因？”

基于用户的4类需求，谷歌针对性设计了3个Agent各司其职：

- 需求2（个人数据理解）=> **数据分析Agent**
- 需求1（一般健康知识）+ 需求4（个人症状解释）=> **领域专家Agent**
- 需求3（健康与生活方式建议）=> **健康教练Agent**

同一大模型底座

Gemini 2.0 (Flash/Pro)

PHA

编排器智能体 Orchestrator

“指挥官”

负责拆任务、派活、整合结果

数据分析智能体 DS Agent

“数据分析师”

制定分析计划、写代码

领域专家智能体 DE Agent

“医学顾问”

查权威资料，解释健康问题

健康教练智能体 HC Agent

“私人教练”

负责定目标、给行动建议

相较底座新增能力

意图识别 / 用户需求映射

任务拆分 + 顺序协作流

主Agent与辅助Agent动态调度

记忆 / 状态管理

计划 → 代码两阶段流水线

Python 沙箱代码执行

失败重试与自纠错

可穿戴数据接入（WEAR-ME 多表）

推理-调查-检验循环（多步执行）

Web搜索

NCBI 文献API

DataCommons

Python沙盒


多模态融合（可穿戴+化验+病史）

模块化教练引擎（动机访谈为核心）

建议时机控制（何时给建议）

会话结束判定（自然终点/总结）

健康Agent助手 - 流程示例




(已落地Fitbit Premium)

• AI的未来是什么样的？未来AI会取代人类吗？



“我问它如果AI统治地球，能不能放我一马。它笑着说不会统治人类，但我坚持问，它就说“好吧，答应放你一马”。我还报了家人的名字，让它记下来，哈哈！”




不是汽车代替马车，
而是会开车的人取代不会开车的人



阶段1: 预训练 Pretraining

1. 下载10TB左右的文本数据
2. 买/租6000多台的GPU
3. 将文本压缩进模型，花费2千万，等12天
4. 获得 base模型




<USER>
Can you write a short introduction about the relevance of the term "monopsony" in economics? Please use examples related to potential monopsonies in the labour market and one relevant research.

<ASSISTANT>
"Monopsony" refers to a market situation where there is only one buyer for a particular good or service. In economics, this term is particularly relevant in the labor market, where a monopsony employer has significant power over the wages and working conditions of their employees. The presence of a monopsony can result in lower wages and reduced employment opportunities for workers, as the employer has the incentive to increase wages or provide better working conditions.

阶段2: 后训练 Post-training

1. 制定构建对话集的标准
2. 雇人写10万条高质量的问答或偏好集
3. 在该数据集上微调base模型，等1天
4. (可选: 强化学习训练)
5. 获得 assistant/thinking模型
6. 进行一系列评估
7. 部署上线
8. 监控, 收集错误回答, 回到step 1



反馈码



Thank you!